Solventa

Análisis de Modelo Predictivo y Evaluación de Proveedores

Prueba Técnica - Data Scientist Jr.

Fecha: Mayo 2026

Tabla de Contenido

1. Desarrollo de Modelo Predictivo
1.1 Selección de Variable Objetivo
1.2 Análisis Exploratorio de Datos
1.3 Preprocesamiento y Feature Engineering
1.4 Entrenamiento y Comparación de Modelos
1.5 Selección del Punto de Corte
1.6 Limitaciones del Modelo
2. Evaluación de Modelos de Proveedores
2.1 Capacidad Discriminante
2.2 Análisis por Deciles
2.3 Estabilidad del Puntaje (PSI)
2.4 Separación entre Buenos y Malos
2.5 Recomendación de Proveedor
3. Conclusiones y Recomendaciones Finales

1. Desarrollo de Modelo Predictivo

El objetivo de esta sección es construir un modelo que permita calificar a los clientes potenciales del nuevo producto de alto riesgo y seleccionar aquellos con menor probabilidad de incumplimiento. La base de datos **ProductoNuevo.xlsx** contiene 4,315 registros con 22 variables incluyendo información demográfica, financiera y de comportamiento.

1.1 Selección de Variable Objetivo

Se evaluaron dos posibles variables objetivo: **Mora30** (morosidad a 30 días) y **Mora60** (morosidad a 60 días). La distribución observada fue:

- **Mora30:** 24.4% de clientes en mora (1,052 de 4,315)
- **Mora60:** 11.7% de clientes en mora (504 de 4,315)

Decisión: Se seleccionó **Mora30** como variable objetivo.

Justificación:

Para un producto de alto riesgo, detectar morosidad temprana es fundamental. Mora30 permite identificar clientes problemáticos antes de que la situación se agrave, facilitando acciones de cobro preventivas. Además, la mayor proporción de eventos positivos (24.4% vs 11.7%) proporciona más información al modelo para aprender patrones de riesgo.

Figura 1: Distribución de variable objetivo y correlaciones

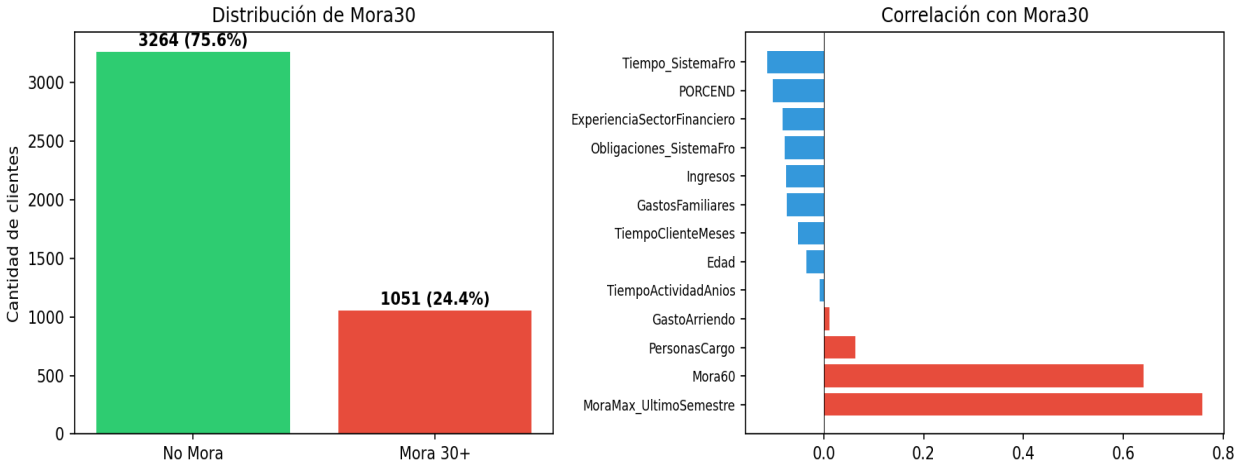

1.2 Análisis Exploratorio de Datos

Se analizaron las relaciones entre las variables categóricas y continuas con la tasa de morosidad. Los hallazgos principales fueron:

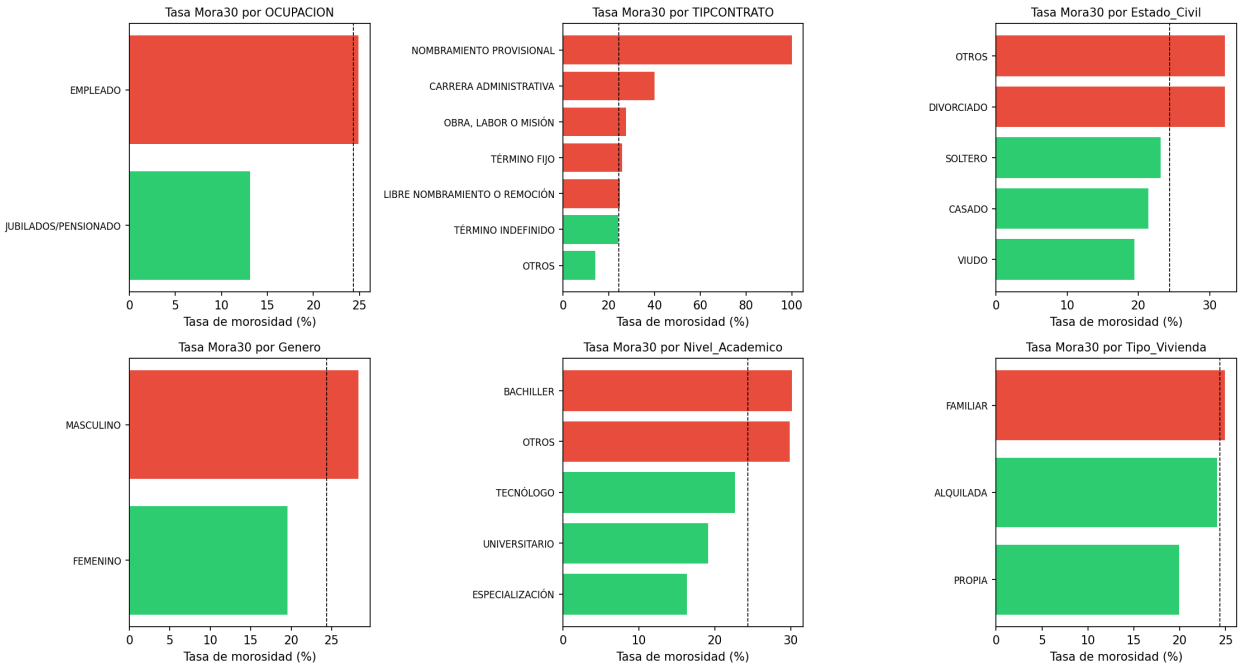

Figura 2: Tasa de Mora30 por variable categórica

1.3 Preprocesamiento y Feature Engineering

Se realizaron las siguientes transformaciones:

- **Encoding:** Label encoding para 6 variables categóricas (OCUPACION, TIPCONTRATO, Estado_Civil, Genero, Nivel_Academico, Tipo_Vivienda)
- **Feature engineering:** Se crearon 4 nuevas variables:

- Debt_to_Income: Ratio de endeudamiento (obligaciones/ingresos)

- Expense_Ratio: Ratio gastos familiares sobre ingresos

- Experience_to_Age: Experiencia laboral relativa a la edad

- Cliente_Years: Antigüedad como cliente en años

Nota importante sobre Data Leakage: La variable **MoraMax_UltimoSemestre** fue excluida del modelo porque contiene información post-evento sobre la morosidad máxima del cliente. Presenta una correlación de 0.76 con Mora30 y, si se incluyera, permitiría predecir perfectamente el target. En un escenario real de originación, esta información no estaría disponible al momento de la decisión de crédito.

La división train/test fue 75/25 con estratificación, resultando en 3,236 registros de entrenamiento y 1,079 de prueba, ambos con 24.4% de tasa de mora.

1.4 Entrenamiento y Comparación de Modelos

Se entrenaron tres algoritmos con hyperparámetros optimizados para evitar overfitting:

Modelo	ROC-AUC	Descripción
Logistic Regression	0.6125	Modelo lineal interpretable, buen baseline
Random Forest	0.6032	Ensemble de árboles, robusto a ruido
Gradient Boosting	0.6011	Ensemble secuencial, alto poder predictivo

El modelo seleccionado fue **Logistic Regression** con un ROC-AUC de 0.6125. Aunque este valor es moderado, es consistente con la complejidad del problema: los datos disponibles tienen poder predictivo limitado para diferenciar entre buenos y malos pagadores.

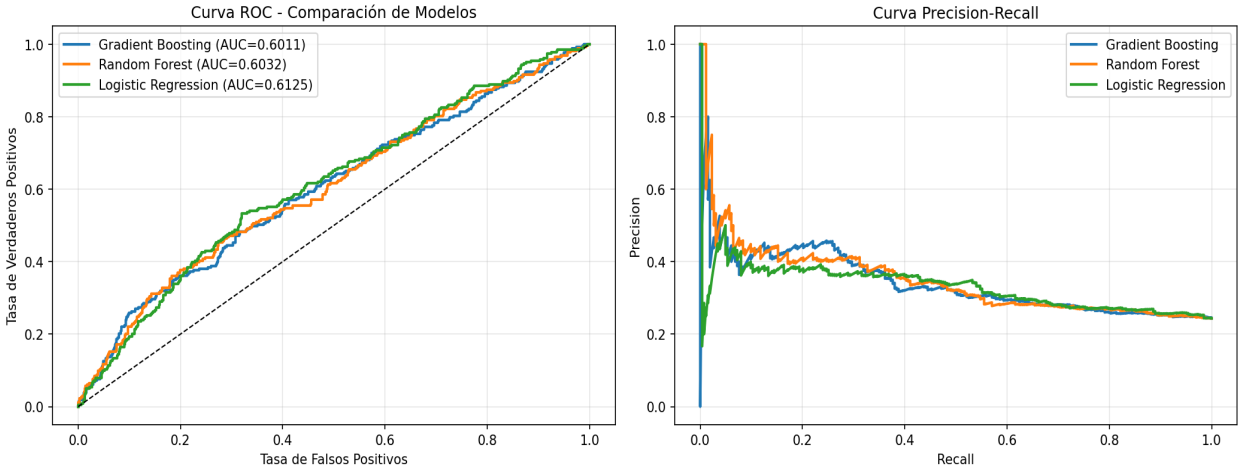

Figura 3: Curvas ROC y Precision-Recall de los modelos

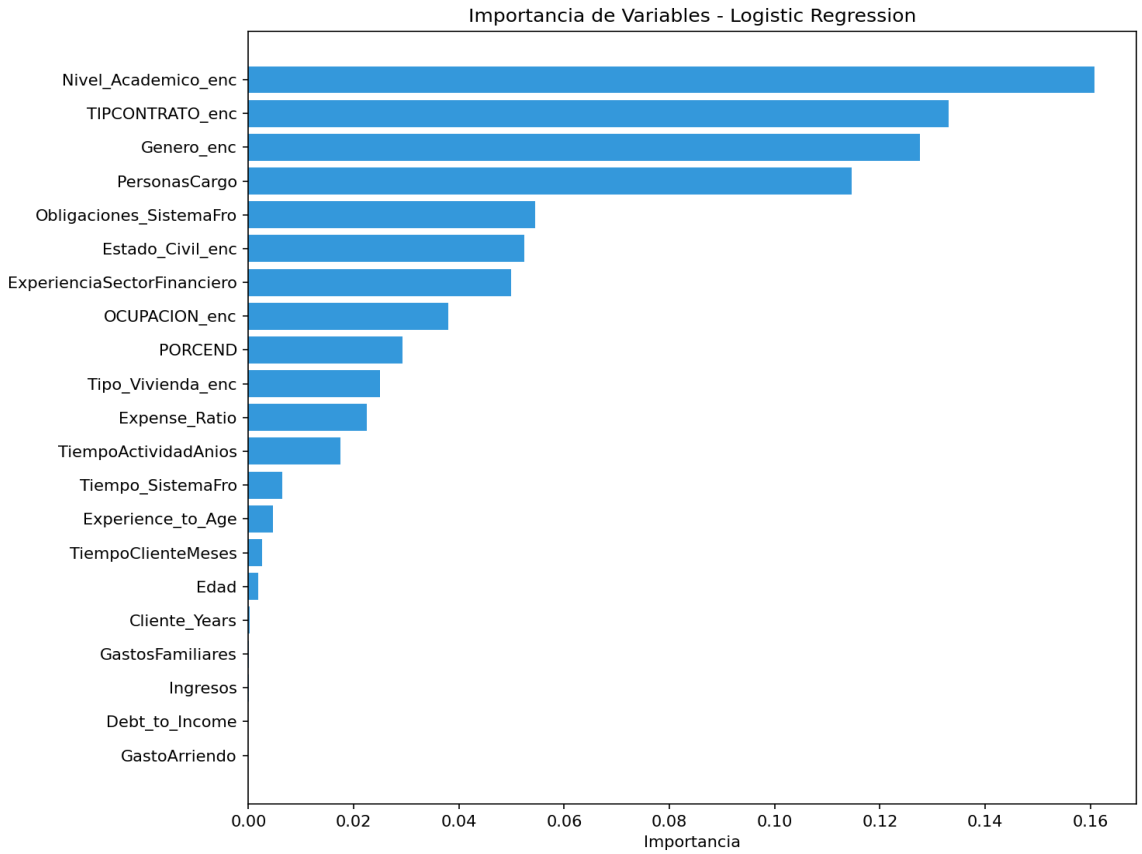

Figura 4: Importancia de variables en el modelo seleccionado

1.5 Selección del Punto de Corte

La selección del punto de corte es crítica para el negocio. Para un producto de alto riesgo, se debe balancear la captura de clientes morosos (recall) con la aprobación de clientes buenos (approval rate).

Punto de corte recomendado: 0.49

Métrica	Valor	Interpretación
ROC-AUC	0.6125	Capacidad discriminante moderada
Precision	0.3050	De los rechazados, {mm["precision"]*100:.0f}% son realmente morosos
Recall	0.5856	Se captura {mm["recall"]*100:.0f}% de los morosos
F1-Score	0.4010	Balance entre precision y recall
Approval Rate	53.2%	Porcentaje de clientes aprobados

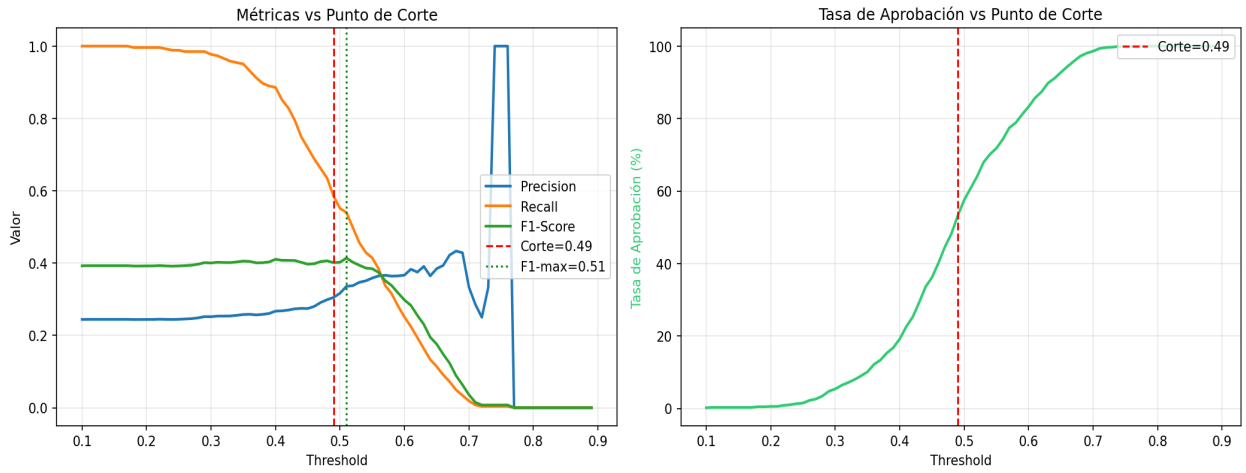

Figura 5: Análisis de punto de corte - métricas y tasa de aprobación

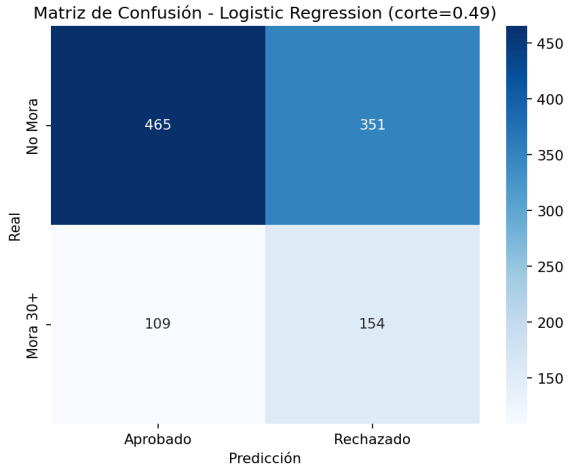

Figura 6: Matriz de confusión

1.6 Limitaciones del Modelo

Las principales limitaciones identificadas son:

- **Poder predictivo moderado (AUC=0.61):** Las variables disponibles tienen capacidad limitada para predecir morosidad. Esto sugiere que factores no capturados en los datos (historial crediticio bureau, comportamiento transaccional) podrían ser determinantes.
- **Variables limitadas:** El dataset no incluye información de buró de crédito, historial de pagos, ni datos transaccionales, que son típicamente los predictores más fuertes en scoring crediticio.
- **Trade-off negocio-riesgo:** Con el punto de corte seleccionado, se rechazan ~47% de los clientes, pero solo se captura ~59% de los morosos. Existe un riesgo residual significativo de aprobar clientes que caerán en mora.
- **Datos estáticos:** La información corresponde a un corte temporal específico (2017-2018). Condiciones macroeconómicas cambiantes pueden afectar la performance del modelo.

2. Evaluación de Modelos de Proveedores

La base **ModelosCompetencia.xlsx** contiene 114,109 registros con los puntajes de dos proveedores (AB y XY) y la variable de default. El análisis se realiza para determinar cuál proveedor ofrece el modelo más efectivo.

2.1 Capacidad Discriminante

La tasa de default en la muestra es **60.45%**, lo que indica un segmento de alto riesgo. Los resultados de capacidad discriminante fueron:

Métrica	Proveedor AB	Proveedor XY	Interpretación
ROC-AUC	0.5013	0.5018	Cercano a 0.5 = sin poder discriminante
KS	0.0052	0.0051	Muy bajo (< 0.10 = pobre separación)
Gini	0.0026	0.0035	Cercano a 0 = sin capacidad predictiva

Hallazgo crítico: Ambos proveedores presentan un ROC-AUC cercano a 0.50 y un estadístico KS inferior a 0.01. Esto significa que **ninguno de los dos modelos tiene capacidad discriminante significativa**. Los puntajes no permiten diferenciar entre clientes buenos y malos de manera efectiva.

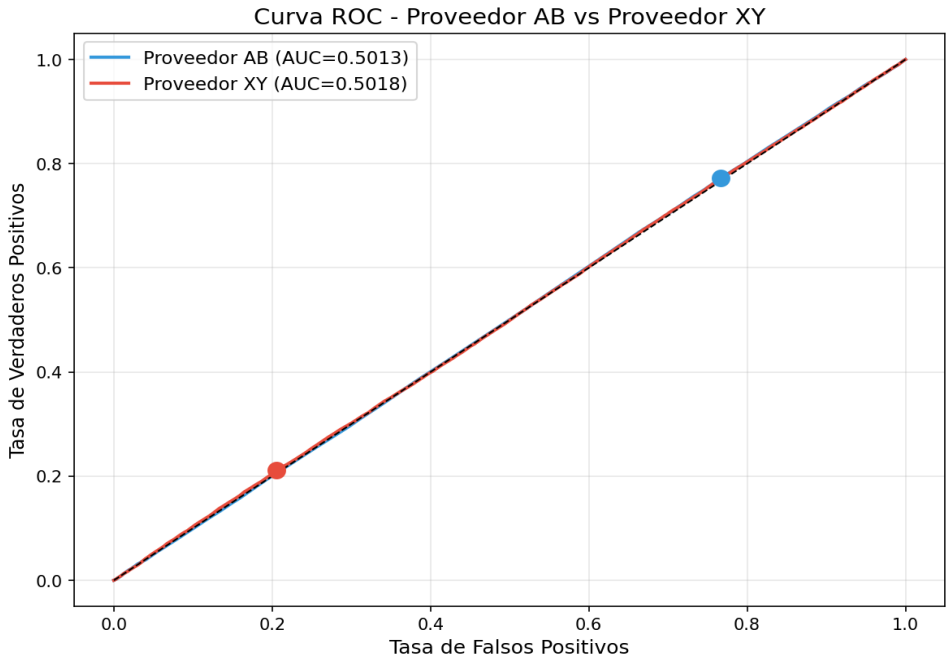

Figura 7: Curva ROC comparativa - ambos modelos cerca del azar

2.2 Análisis por Deciles

Al segmentar los clientes en deciles según el puntaje, se observa que la tasa de default es prácticamente uniforme en todos los rangos para ambos proveedores, sin la monotonicidad esperada (donde deciles más altos deberían tener mayor tasa de default).

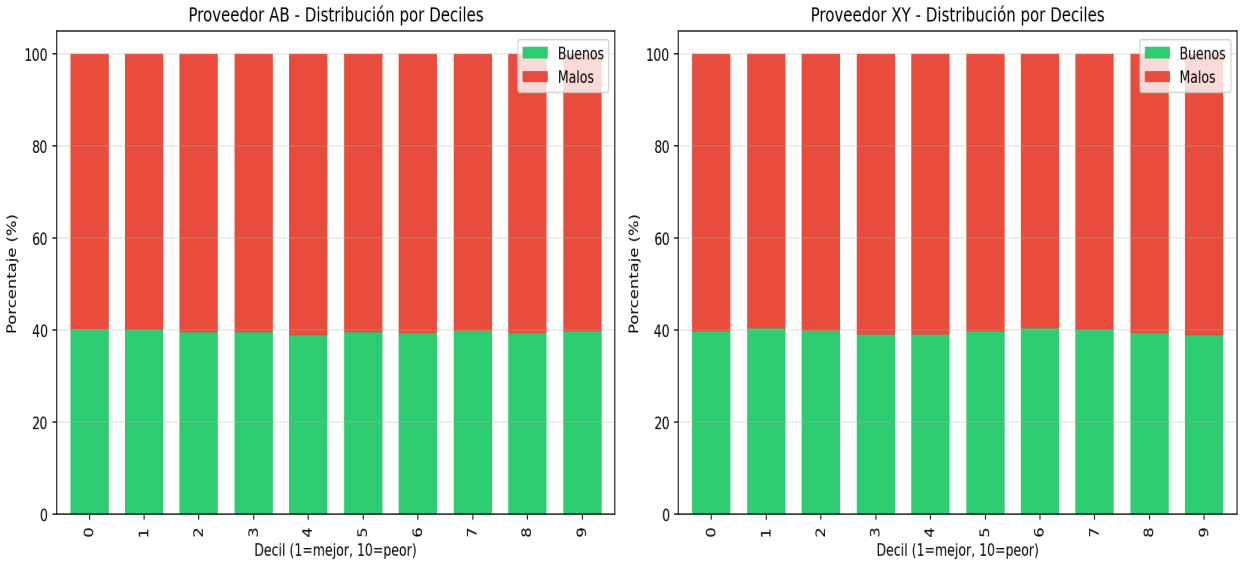

Figura 8: Distribución de buenos y malos por deciles

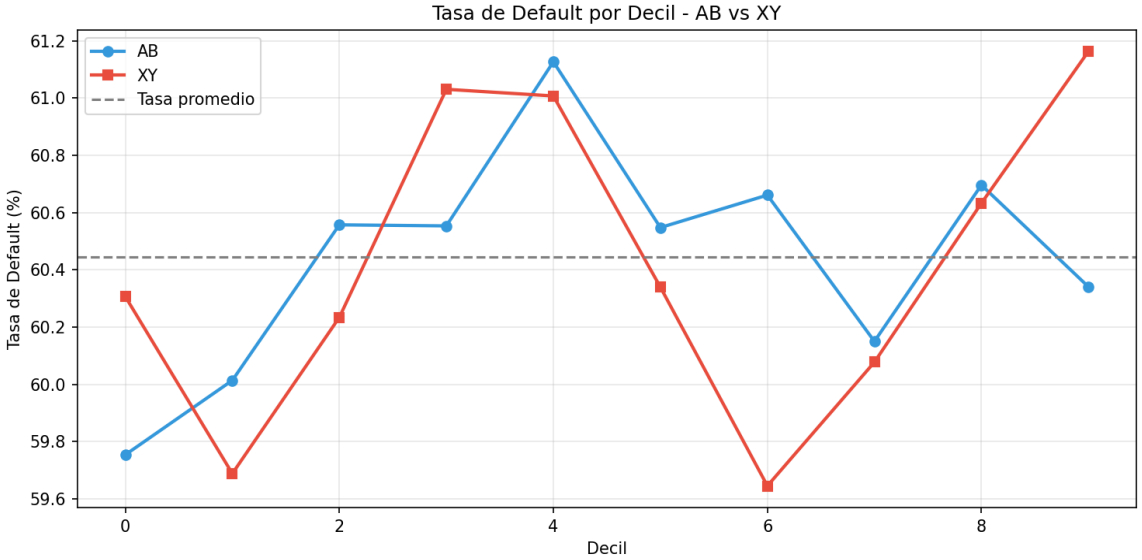

Figura 9: Tasa de default por decil - sin tendencia clara

2.3 Estabilidad del Puntaje (PSI)

- **PSI Proveedor AB:** 0.0006 - Estable
- **PSI Proveedor XY:** 0.0011 - Estable

Ambos modelos muestran estabilidad en sus distribuciones de puntaje a lo largo del tiempo (PSI < 0.10). Sin embargo, la estabilidad no compensa la falta de poder predictivo.

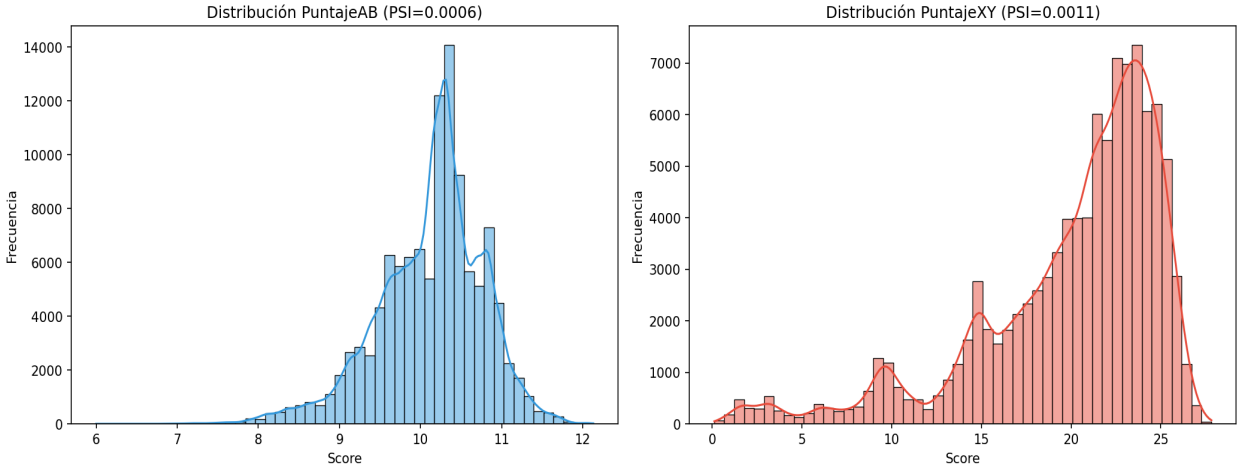

Figura 10: Distribución de puntajes por proveedor

2.4 Separación entre Buenos y Malos

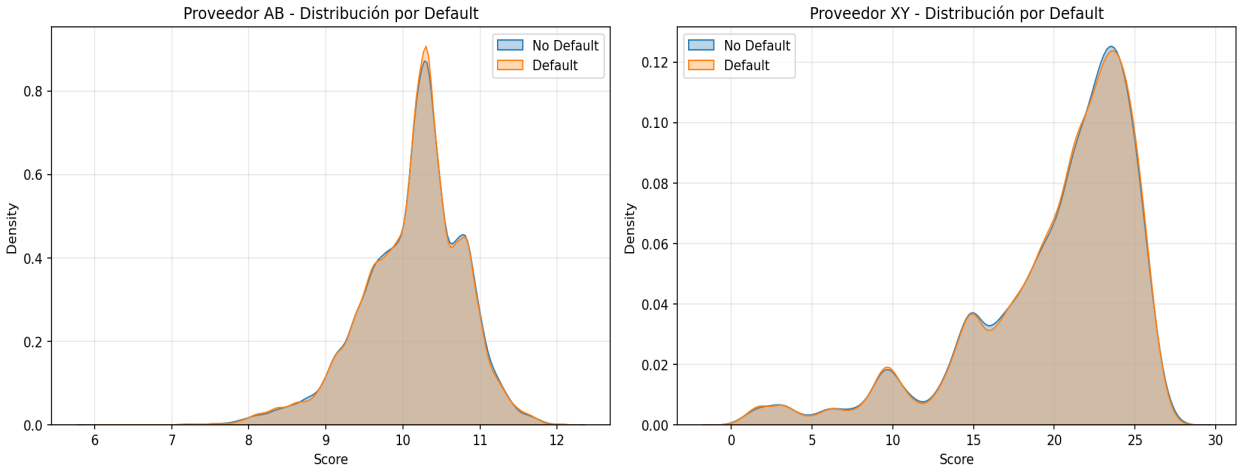

Figura 11: Distribución de scores por default - superposición total

Las curvas de densidad muestran una superposición casi total entre la distribución de scores de clientes buenos y malos. Esto confirma que los puntajes no separan efectivamente a los dos grupos.

2.5 Recomendación de Proveedor

Recomendación: Ninguno de los dos proveedores es adecuado para la tarea.

Si bien el Proveedor XY presenta un AUC marginalmente superior (0.5018 vs 0.5013), la diferencia es estadísticamente insignificante. Ambos modelos tienen un poder discriminante equivalente al azar.

Observaciones adicionales:

- El Proveedor AB tiene cobertura completa (114,109 registros) mientras que XY tiene 11.2% de datos faltantes (12,800 registros sin puntaje), lo cual es una limitación operativa importante.

• El rango de scores de AB es muy estrecho (6.0 a 12.1, std=0.65) mientras que XY tiene mayor variabilidad (0.1 a 27.8, std=5.19), pero ninguna se traduce en poder predictivo.

• Se recomienda explorar proveedores alternativos o desarrollar un modelo interno que incorpore variables de buró de crédito y datos transaccionales.

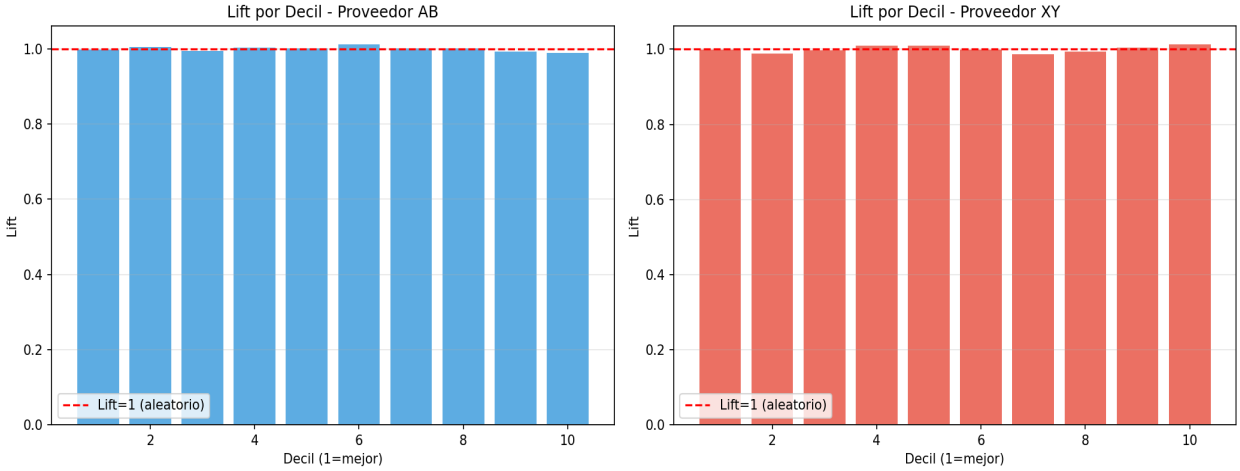

Figura 12: Análisis de Lift por decil - sin lift significativo

3. Conclusiones y Recomendaciones Finales

3.1 Sobre el Modelo Predictivo Interno

Se logró construir un modelo con ROC-AUC de 0.61, que si bien es moderado, representa un punto de partida útil para la selección de clientes del nuevo producto. El modelo de Logistic Regression fue seleccionado por su interpretabilidad y performance comparable a modelos más complejos.

Recomendaciones:

- Incorporar variables externas: datos de buró de crédito, historial de pagos, variables macroeconómicas.
- Implementar un proceso de monitoreo continuo con recálculo del modelo cada trimestre.
- Definir políticas de aprobación por segmento, no solo por score (ej: diferentes thresholds por rango de ingresos o tipo de ocupación).

3.2 Sobre los Proveedores

Ambos proveedores evaluados (AB y XY) presentan modelos sin capacidad discriminante significativa (AUC ≈ 0.50). **No se recomienda contratar a ninguno** en su estado actual. La inversión en estos proveedores no generaría valor agregado respecto a una selección aleatoria de clientes.

3.3 Recomendación Estratégica

Dada la debilidad tanto del modelo interno como de los proveedores evaluados, se recomienda:

1. **Enriquecer los datos:** Integrar fuentes adicionales de información crediticia para mejorar el poder predictivo.
2. **Desarrollar modelo interno robusto:** Con mejores datos, un modelo interno puede superar a proveedores externos y ser más económico a largo plazo.
3. **Implementar políticas complementarias:** Además del score, usar límites de crédito diferenciados, períodos de prueba, y garantías para mitigar el riesgo en este segmento.
4. **Monitoreo riguroso:** Establecer KPIs de performance del modelo (vintage analysis, roll rates, PSI) para detectar degradación temprana.